

특집

딥러닝, 소음진동분야에도 유용한가?

딥러닝, 소음진동분야에도
유용한가?

이 승 철*, 이 수 영

(포항공과대학교)

1. 머리말

최근 빅데이터, AI 알고리즘 및 하드웨어의 발전이 이루어지면서 머신러닝(machine learning)이 다양한 분야에서 우수한 성능을 보여주고 있다. 특히 머신러닝 알고리즘 중에서도, 심층 신경망 구성을 통한 비선형 변환 기법을 활용하는 딥러닝(deep learning)의 발전은 컴퓨터 비전(computer vision), 자연어 처리, 음성 인식 등의 분야에서 괄목할만한 성능을 발휘하고 있다. 가령, 시각과 청각 등 사람의 인지 및 사고방식을 기계에게 가르치기 위한 많은 연구들은 영상 인식, 음성 인식 등에 활용될 수 있는 CNN(convolutional neural network), RNN(recurrent neural network)과 같은 다양한 종류의 심층 신경망 구조를 탄생시키면서 딥러닝 시대의 도래에 크게 기여하였다. 이러한 발전의 우수성을 인정받아 제조, 의료, 금융 산업 등에서 널리 응용되고 있으며, 이의 적용 분야는 급진적으로 확대되고 있다.

이러한 딥러닝은 소음진동분야에도 유용하게 활용될 수 있다. 기존에는 취득된 진동, 음성 등 신호 데이터의 특성을 추출하고 이를 분석하기 위해 많은 도메인 지식이 요구되어 왔다. 따라서, 지금까

지 데이터의 특징 분석 및 판단이 개별적인 전문가의 영역에서 다루어 왔다. 하지만, 취득된 데이터를 분석하고 판단하기 위해 특성 학습(feature learning)까지 수행할 수 있는 딥러닝 모델의 활용도가 높아짐에 따라 이와 관련한 연구가 활발히 진행되고 있다. 특히, 소음진동분야에서 취득할 수 있는 신호 데이터는 시계열 특성을 보유하고 있을 뿐만 아니라, 활용할 수 있는 다양한 센서 및 도메인 지식 기반 전처리를 통해 영상, 이미지의 특성을 가질 수도 있기 때문에 인공지능 적용을 위해 무한한 가능성을 보유한 분야이다. 우리는 이러한 특징을 바탕으로 딥러닝 모델을 잘 활용한다면 혁신을 가져올 수 있다는 것을 여러 연구 사례 및 문헌을 통해 확인할 수 있다.

이 글에서는 소음진동분야에 딥러닝 기술이 유용하게 활용된 대표적 연구 사례를 소개하고자 한다. 특히, 데이터의 측면에서 진동 신호/열화상/음성 신호 기반 딥러닝 응용 연구 사례를 통해, 딥러닝이 소음진동분야에 활용되고 있는 연구 사례와 이에 대한 동향에 대해 전달하고자 한다. 마지막으로, 해당 분야에 딥러닝 기술을 활용하기 위한 연구를 수행하기 위해 도움이 될만한 자료들을 제시하고자 한다.

* E-mail : seunglee@postech.ac.kr

2. 소음진동분야 딥러닝 응용 연구 사례

2.1 진동 신호 기반 딥러닝 응용 연구 사례

진동 데이터 기반 딥러닝 응용이 가장 활발한 분야 중 하나는 건전성 예측 및 관리(prognostics and health management) 분야로, 이는 다양한 기계시스템 및 설비에서 획득되는 데이터를 기반으로 이상을 진단(diagnostics)하고 예지(prognostics)하는 것을 포함한다. 진단은 시스템의 고장 모드를 탐지하는 등의 상황 분석을 일컫고, 예지는 관측된 현상을 기반으로 향후 고장이 발생하는 시점을 예측하는 등의 상황 예측으로 정의된다⁽¹⁾. 빅데이터, 딥러닝 알고리즘의 발달은 기존 모델 기반(model-based) 방법론에서 데이터 기반(data-driven) 방법론으로 변모하는데 기인하였으며, 이를 기반으로 다양한 딥러닝 기술이 진단 및 예지를 위해 활용될 수 있다.

가령, 많은 기계시스템 및 설비를 이루고 있는 베어링, 기어 등의 부품에서 획득된 진동 데이터에 딥러닝 기술을 활용하여 높은 성능의 고장 진단 모델을 구축할 수 있다. 관측되는 원신호는 유용할만한 정보를 담고 있지 않은 경우가 빈번하며 내륜, 외륜 베어링 등 대상의 유형마다 고장 특성도 상이하다. 아울러, 이는 여전히 도메인 의존도가 높아 전문가가 판단하는데 많은 비용이 발생한다. 신호 데이터의 전처리 방법인 단시간푸리에변환(short-time Fourier transform), 웨이블릿 변환(wavelet transform)을 통해 원신호의 주파수 대역과 시간

변화를 시각적으로 파악할 수 있는 스펙트로그램(spectrogram) 또는 스칼로그래ם(scaleogram)으로 변환한 뒤, 시각적 이미지 분석에 널리 사용되는 심층 신경망인 CNN을 통한 모델링으로 이의 성능을 획기적으로 개선할 수 있다⁽²⁾. 이 합성곱 신경망은 이미지에 특화된 컨볼루션 연산을 활용하여, 신경망의 층을 통과할수록 공간적 정보(spatial information)를 추출하기 때문에 시간-주파수 특성 분석에 용이하다. 그 결과, 육안으로 차이를 구분할 수 없는 데이터로부터 CNN을 통해 고차원 정보를 추출함으로써 각기 다른 범주의 데이터를 쉽게 구분할 수 있으며 특징인자 학습(feature learning)과 분류(classification)을 동시에 수행하는 end-to-end 프레임워크의 장점을 활용할 수 있다. 해당 연구 사례로 필자의 연구팀은 STFT, WT 등의 적절한 전처리와 CNN 모델 학습 및 최적화를 통해 베어링의 결함 유무를 100 % 정확도로 판별한 바 있으며⁽²⁾, 총 7개의 고장 유형까지도 높은 정확도로 판별할 수 있음을 입증한 바 있다.

위 사례가 데이터 특성에 대한 명시적인 답, 즉 범주의 레이블(label)이 존재하는 지도학습(supervised learning)의 예라면, 답이 존재하지 않는 비지도학습(unsupervised learning)에도 딥러닝 기술이 적용될 수 있다. 실제 고장 진단을 필요로 하는 현장에서 비지도학습이 중요한 경우가 많은데, 이는 앞으로 관측될 데이터가 기존 이력의 데이터 특성을 완전히 대변할 수 없다는 불확실성이 존재하기 때문이다. 따라서, 입력에 대한 출력이 존재하지 않는 이 경우에는 딥러닝 모델은 분류

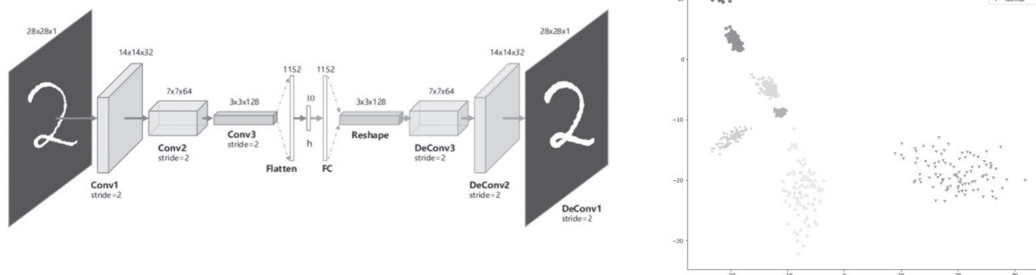


그림 1 CNN 기반 오토엔코더 구조 및 고장 유형에 따른 잠재 변수 시각화

가 아닌 데이터의 패턴 혹은 분포의 대표성(representation)을 추출하기 위해 학습된다. 필자의 연구팀은 CNN 모델을 기반으로 출력을 입력과 동일하게 설정한 뒤, 네트워크가 이를 최대한 복원(reconstruction)할 수 있도록 학습하여 데이터 이면에 존재하는 잠재 변수(latent variables)를 추출한 바 있다⁽³⁾. 입력을 잠재 변수로 표현하는 인코더(endoer) 구조와 이를 다시 출력으로 표현하는 디코더(decoder) 구조로 구성된 오토인코더(autoendoer) 모델을 구축하여 데이터를 잠재 공간(latent space)에서 표현할 수 있다. 7개의 고장 유형에 대한 비지도 학습 결과를 그림 1에 나타내었으며, 각 고장 유형에 해당하는 잠재 변수의 군집적인 특성을 나타내는 것을 확인할 수 있다. 이와 같은 딥러닝 기반 데이터의 잠재 특징 추출 및 군집 특성을 통해 비관측 데이터에 대해서도 이상치 탐지(anomaly detection)의 정합성을 달성할 수 있을 것으로 기대된다.

마지막으로, 기계시스템 및 설비의 수명을 예측하기 위해 딥러닝 기술이 활용될 수 있다. 과거부터 현재까지 관측되어 온 진동 데이터의 특성을 분석함으로써 고장 시점 즉, 기대 수명까지의 시간을 나타내는 RUL(remaining useful life)을 예측할 수 있으며 이 과정에서 딥러닝이 활용되는 사례가 늘어나고 있다. 시계열 데이터 해석에 가장 널리 사용되는 딥러닝 알고리즘은 RNN(recurrent neural network)으로, 이는 시계열 데이터에 내재되어 있는 패턴과 특성 파악에 유용한 심층 신경망 중에 하나이다. 단순한 순방향(feedforward) 신경망과 달리, RNN은 구조적으로 은닉상태(hidden

state)를 활용하는 재귀적인 모델링을 활용한다. 아울러, 은닉상태를 통해 메모리를 할당하기 때문에 과거 정보가 다음 단계로 전달될 수 있는 구조를 가지고 있다(그림 2). 기존 RUL을 예측하기 위한 HI(health indicator)는 주로 진동 신호의 통계적 특성에 의존해왔으나, 이러한 HI는 시계열 패턴을 온전히 대변하는 데에 한계가 있었다. Liang, G. 연구팀은 딥러닝을 활용하여 이를 획기적으로 개선하기 위해 RNN 기반 HI와 예측 모델을 제시하였으며, 이를 통해 높은 베어링 수명 예측 정확도를 달성하였다⁽⁴⁾.

2.2 열화상 기반 딥러닝 응용 연구 사례

열화상(thermal imaging) 데이터를 기반으로 딥러닝 활용하여 유용한 결과를 얻은 사례도 존재한다. 기존 진동 신호 데이터의 경우, 적용 대상 시스템의 특성에 따라 데이터를 취득하기 위해 많은 센서를 부착해야 한다는 단점이 있다. 또한, 센서 부착시에 센서 개수 및 설치 위치 최적화 등의 이슈가 생길 수 있으며, 기계시스템과 설비 등이 작동하면서 많은 외부 간섭이나 노이즈를 포함하는 데이터를 측정할 가능성도 있다. 이러한 단점을 극복하기 위해 열화상 데이터를 이용, 영상 기반 딥러닝 모델을 구축하여 건전성 관리 및 상태 모니터링을 수행한 연구가 증가하고 있다.

Jia, Z. 연구팀은 IRT(infrared thermography)를 활용한 딥러닝 모델을 구축하여 높은 성능으로 회전체 고장을 진단할 수 있음을 제시한 바 있다⁽⁵⁾. 전체 회전체에서 진단을 위한 관심 영역(region of interest)의 영상을 분리하여, 외륜, 내륜 베어링




그림 2 RUL 그래프 및 RNN 구조

결합 등의 부품 고장을 진단할 뿐만 아니라 질량 불평형(mass unbalance), 러빙(rubbing) 등의 시스템 전체의 고장 진단까지 수행할 수 있는 알고리즘을 구축하였다(그림 3). 전통적인 이미지 처리 알고리즘인 SIFT(scale invariant feature transform)를 수행한 뒤 머신러닝 분류 알고리즘을 구축하였고, 특성 학습 및 분류의 통합 프레임워크를 활용하는 딥러닝 분류 알고리즘으로 CNN도 구축한 뒤 둘의 분류 정확도를 비교하였다. 각각 99.8%와 100%의 분류 성능을 보이며 딥러닝 모델의 우수성을 보여주었다.

Li, Y. 연구팀 또한 IRT를 기어박스의 상태 모니터링에 활용하여 CNN 딥러닝 모델을 구축한 연구를 발표하였다⁽⁶⁾. 해당 연구 사례에서는 기어의 기존 접촉 방식 진동 신호 취득과 분석의 단점을 보완하기 위하여 비접촉 방식의 열화상 데이터

와 이미지에 특화된 인공신경망인 CNN을 활용하여 높은 정확도를 달성할 수 있는 모델을 개발하였다. 실험에는 베벨 기어로 구성된 시뮬레이터를 사용하였으며, 모니터링 범주는 정상 상태를 포함, PT(pitting in the tooth), BT(broken tooth), MT(missing tooth), CT(crack in the tooth), PC(pitting and crack), BC(broken and crack), MC(missing and crack) 총 8개를 사용하였다(그림 4). 이때 주목해야 할 부분은 그림 4와 같이 범주별 취득된 열화상이 육안으로 구별하기 매우 힘들다는 것이다. 그러나, 최적화된 CNN 모델을 통해 해당 이미지를 효과적으로 처리하고 많은 정보를 담고 있는 특성 인자를 추출해내게 되며, 결국 CNN 모델은 해당 열화상을 분류하기 위해 보다 우수한 특성 공간(feature space)을 스스로 학습한다(그림 5). 이 제안된 딥러닝 기반 상태 모니터링

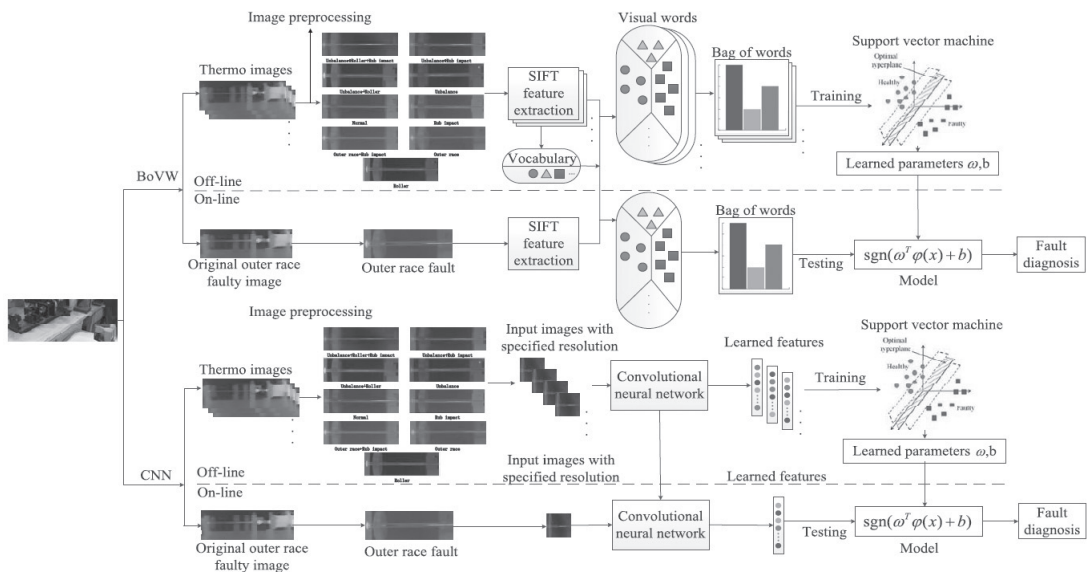


그림 3 IRT 이미지 기반 기계시스템 고장 진단의 머신러닝, 딥러닝 모델⁽⁵⁾




그림 4 범주별 기어박스 열화상 데이터 및 CNN 아키텍처⁽⁶⁾

기법은 100 %의 정확도를 보이며 이의 우수성을 입증하였다.

2.3 음성 신호 기반 딥러닝 응용 연구 사례

음향(acoustics) 및 오디오 신호 처리(audio signal processing) 분야에서 딥러닝이 가장 활발하게 활용되는 분야는 음성 인식(speech recognition)과 음향 이벤트 인식(sound event detection) 분야이다⁽⁷⁾. 해당 분야에서 기존의 물리 기반 모델이 딥러닝을 적용한 데이터 기반 모





그림 5 열화상 기반 CNN 모델의 PCA 기반 특성 인자 시각화⁽⁶⁾

델로 변하고 있는 추세이다.

음향 이벤트 인식 분야에 딥러닝을 적용한 가장 유명한 사례를 꼽으라면 단연 2017년에 DCASE(detection and classification of acoustic scenes and events) 챌린지에서 우승한 Cakir, E. 연구팀의 연구 사례이다⁽⁸⁾. 우리가 살아가는 일상 생활과 유사한 다원 조건에서의 음향 탐지 시스템 개발을 위해 Cakir, E. 연구팀은 CNN(convolutional neural network)과 RNN(recurrent neural network) 구조를 동시에 활용하여 높은 성능의 모델을 개발할 수 있었다. 앞서 언급한 바와 같이 CNN은 주파수 대역 정보와 시간 정보를 효율적인 고차원 특성으로 추출하는 데 장점이 있으며, RNN은 시간적 패턴 특성을 추출할 수 있는 장점을 갖고 있다. 이러한 두 가지 장점을 결합한 CRNN(convolutional recurrent neural network) 모델을 제시하였다(그림 5). 우선 음성 신호의 소리 특징을 추출하기 위해 MFCC(mel frequency cepstral coefficient) 방법으로 구간별 스펙트럼 특징을 추출하게 되며, 이 TFR(time-frequency representation) 이미지가 컨볼루션 레이어를 거치게 된다. 주파수 방향으로의 연속된 컨볼루션 연산, 그리고 추출된 특성맵(feature map) 시퀀스

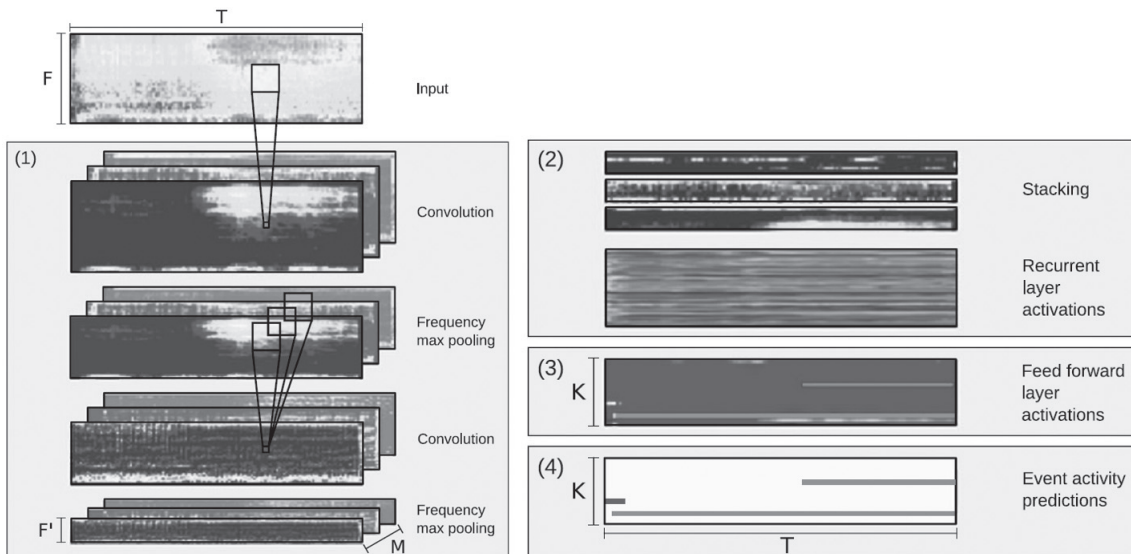


그림 6 다음성 인식을 위해 제안된 CRNN 모델 구조⁽⁸⁾

(sequence)의 RNN 모델링을 통해 다음성 인식(polyphonic sound event detection)에 최적화된 모델을 제시한 바 있다. 다음성 인식이라는 목적에 맞는 전처리 및 네트워크 구조 설계를 수행했다는 점에서 많은 의미를 담고 있다.

음성 데이터와 딥러닝을 활용해 의학적 진단을 돕는 연구도 활발히 진행되고 있다. 기존 병리학 적 음성(pathological voice)을 진단하기 위해서는 높은 비용이 들뿐더러, 외과적(invasive) 방법이 사용되는 단점이 있다. 비외과적(non-invasive) 방법을 활용함과 동시에 진단에 필요한 비용을 획기적으로 줄이기 위해, 딥러닝 기술을 환자의 음성 신호 분석에 활용한 연구가 진행되었다⁹⁾. 필자의 연구팀은 몇 가지 유형의 기침 소리를 담고 있는 음성 데이터를 머신러닝과 딥러닝 방법을 통해 연하장애(dysphagia)를 판별할 수 있는 모델을 개발한 바 있다. 정상인과 연하장애를 갖고 있는 환자의 기침 소리를 담은 데이터를 STFT, MFCC 등의 전처리를 적용한 후, CNN 모델 학습 및 최적화를 통해 환자를 진단할 수 있는 알고리즘 제시한 바 있으며 매우 높은 성능으

로 구별할 수 있다는 것을 확인하였다(그림 6). 아울러, 전처리를 사용하지 않고 음성 원신호 자체에서 1D CNN을 적용하여 전처리에 필요한 도메인 지식을 최소화하고 진단에 소요되는 시간을 획기적으로 낮추기 위한 연구를 수행하고 있다. 이와 같이, 이 연구팀은 서울성모병원, 부천성모병원 등의 의료기관과 협력하여 딥러닝 기반 판별 및 분석에 대한 연구를 수행하고 있으며, 특히 사람의 생명과 관련된 의료 분야인 만큼 매우 뛰어난 성능과 더불어 강건한 알고리즘을 개발하고 적용하는 연구를 지속하고 있다.

3. 딥러닝 활용을 위한 자료

필자가 연구를 수행하고 있는 산업인공지능 연구실은 인공지능에 대한 관심을 증대하고, 인공지능 연구의 확산을 위하여 노력하고 있다. 교육 기관 및 산업, 연구기관에서 인공지능 관련 강연과 강습회를 100여 차례 넘게 진행하는 등 이 연구팀의 연구 사례 및 실적을 소개하고, 궁극적으로 산업계와 연구 분야 전반에 인공지능을 적용

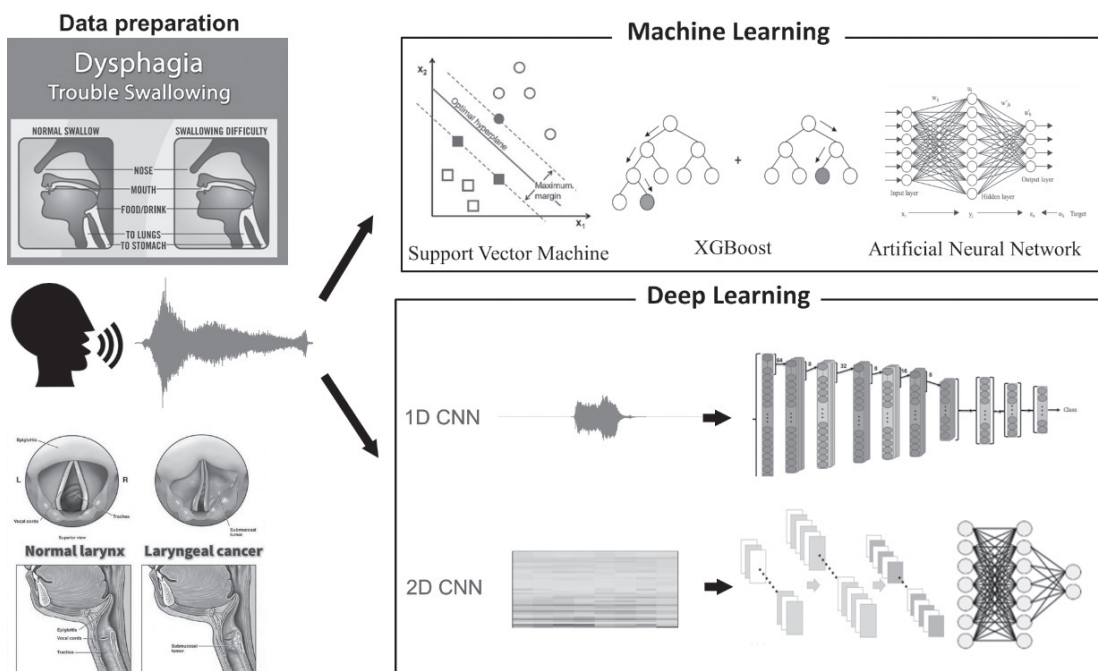


그림 7 음성 신호 기반 머신러닝, 딥러닝을 활용한 연하장애 판별 모델

한 연구가 확산될 수 있도록 노력하고 있다. 또한, 인공지능 연구의 확산을 위해 머신러닝, 딥러닝 관련 MOOC 강의를 촬영하여 제공하며 이에 대한 개념과 알고리즘 코드를 공개하고 있다. 위 관련한 자료는 포항공과대학교 산업인공지능 연구실 홈페이지(<http://iai.postech.ac.kr>)에서 확인할 수 있다.

4. 맺음말

진동 신호, 열화상 및 음성 신호 기반 딥러닝 응용 연구 사례를 통해 소음진동분야에도 딥러닝이 유용하게 활용될 수 있다는 것을 살펴보았다. 여러 분야에서 취득된 데이터를 분석하고 특성 학습(feature learning)을 활용할 수 있는 딥러닝 모델의 활용도가 높아지고 있으며, 이에 대한 연구가 활발히 수행되고 있다. 소음진동분야에서 취득할 수 있는 데이터 및 활용할 수 있는 도메인 지식을 바탕으로, 딥러닝을 잘 활용한다면 혁신을 가져올 수 있을 것이며 무한한 가능성이 있을 것으로 기대된다. **KSNVE**

참고문헌

- (1) Lee, J., Wu, F., Zhao, W., Ghaffari, M., Liao, L. and Siegel, D., 2014, Prognostics and Health Management Design for Rotary Machinery Systems-reviews, Methodology and Applications, Mechanical Systems and Signal Processing, Vol. 42, pp. 314~334.
- (2) 이수영, 전주형, 이강산, 김정찬, 최태규, 이승철, 2019, 베어링 결함 진단 및 분류를 위한 데이터 전처리와 머신러닝, 한국소음진동공학회 2019년도 추계학술대회 초록집, p. 207.
- (3) 전주형, 이수영, 이강산, 최태규, 김정찬, 이승철, 2019, 딥러닝 기반 베어링 결함 비이상 탐지 방법, 한국소음진동공학회 2019년도 추계학술대회 초록집, p. 86.
- (4) Liang, G., Naipeng, L., Feng, J., Yaguo, L. and Jing, L., 2017, A Recurrent Neural Network based Health Indicator for Remaining Useful Life Prediction of Bearings, Neurocomputing, Vol. 240, pp. 98~109.
- (5) Jia, Z., Liu, Z., Vong, C. M. and Pecht, M., 2019, A Rotating Machinery Fault Diagnosis Method based on Feature Learning of Thermal Images, IEEE Access, Vol. 7, pp. 12348~12359.
- (6) Li, Y., Gu, J. X., Zhen, D., Xu, M. and Ball, A., 2019, An Evaluation of Gearbox Monitoring using Infrared Thermal Images Applied with Convolutional Neural Networks, Sensors, Vol. 19, pp. 2205~2220.
- (7) Bianco, M. J., Gerstoft, P., Traer, J., Ozanich, E., Roch, M. A., Gannot, S. and Deledalle, C. A., 2019, Machine Learning in Acoustics: Theory and Applications, Journal of the Acoustical Society of America, Vol. 146, pp. 3590~3628.
- (8) Cakir, E., Parascandolo, G., Heittola, T., Huttunen, H. and Virtanen, T., 2017, Convolutional Recurrent Neural Networks for Polyphonic Sound Event Detection, IEEE Transactions on Audio, Speech, and Language Processing, Vol. 25, pp. 1291~1303.
- (9) 전주형, 황윤섭, 정일주, 한연재, 임선, 이승철, 2019, 딥러닝 기반 병리학적 음성 진단 시스템, 한국소음진동공학회 2019년도 추계학술대회 초록집, p. 85.